

**Universidade Estadual de Campinas**  
**Instituto de Matemática, Estatística e Computação Científica**  
**Departamento de Estatística**

## **Relatório**

**Hugo Calegari RA:155738**  
**Leonardo Uchoa Pedreira RA:156231**

**Professor: Verônica**

**Campinas-SP, 29 de Junho de 2017**

## Introdução Bootstrap

O método de bootstrap faz parte de uma classe de métodos não-paramétricos de Monte Carlo que estimam a distribuição de uma população ou uma característica (parâmetro de interesse) por meio de reamostragem.

Métodos de reamostragem consideram as amostras como uma população finita, a partir da qual reamostras são tomadas para estimar características e realizar inferências a respeito desta população.

## Inferências baseadas em percentis pelo método de bootstrap

Ao se comparar dois grupos independentes, o método é aplicado como segue. Gera-se amostra por bootstrap para cada grupo:

- Para o  $j$ -ésimo grupo, obter amostras de bootstrap via amostragem aleatória com reposição ( $n_j$ ) da seguinte amostra:  $X_{1j}, \dots, X_{n_j}$ , para obter a seguinte:  $X_{1j}^*, \dots, X_{n_j}^*$ ;

Seja  $\hat{\theta}_j^*$  a estimativa por bootstrap de  $\theta_j$ , tal que este parâmetro está associado com alguma característica de interesse. Seja, ainda,  $D^* = \hat{\theta}_1^* - \hat{\theta}_2^*$ . Ao se repetir este processo  $B$  vezes (quantidade de réplicas) gera-se  $D_1^*, \dots, D_B^*$ . Defina  $l = \frac{\alpha}{2}B$  (determinação do limite inferior do intervalo de confiança), arredonde para o inteiro mais próximo, e  $u = B - l$  (limite superior). Com isso, um intervalo de confiança aproximado de  $1 - \alpha$  para a diferença entre os verdadeiros parâmetros ( $\theta_1 - \theta_2$ ) é:  $[D_{(l+1)}^*, D_{(u)}^*]$ , em que  $D_{(1)}^* \leq \dots \leq D_{(B)}^*$ .

Uma vez que se quer testar a hipótese:  $H_0 : \theta_1 = \theta_2$ , pode-se utilizar as seguintes estruturas de acordo com o que segue. Para as estimativas de bootstrap de  $\hat{\theta}_1^*$  e  $\hat{\theta}_2^*$ , seja  $p^* = P(\hat{\theta}_1^* > \hat{\theta}_2^*)$  (pode-se estimar esta probabilidade com o uso da proporção de  $\hat{\theta}_1^* > \hat{\theta}_2^*$ ).

Sob a hipótese nula (igualdade dos verdadeiros parâmetros), assintoticamente (para  $n$  e  $B$  suficientemente grandes),  $p^*$  tem distribuição uniforme. Assim, rejeita-se  $H_0$  se  $p^* \leq \alpha/2$  ou se  $p^* \geq 1 - \alpha/2$ . Neste caso, a forma como foi estimado o valor de  $p^*$  é:

- Seja  $A$  número de valores que são maiores que zero para todos os valores das diferenças obtidos via bootstrap, isto é, entre os valores  $D_1^*, \dots, D_B^*$ . Consequentemente, pode-se estabelecer:  $p^* = A/B$ .

Por conveniência é adotado a o seguinte valor de  $p$  estimado:  $p_m^* = \min(p^*, 1 - p^*)$  (chamado de  $p$ -valor generalizado). Com isso, rejeita-se  $H_0$  se  $p_m^* \leq \alpha/2$ .

## Comparação de M-estimadores

Os M-estimadores que serão avaliados são os de locação. Quando se compara estes estimadores com dois grupos independentes, ainda se percebe que a inferência baseada nos percentis por meio do método de bootstrap é o melhor método. Um intervalo de confiança baseado na estimativa do erro padrão fornecerá boa probabilidade de cobertura quando o tamanho amostral é suficientemente grande, ou seja, para se ter razoável aproximação do erro padrão necessita-se de uma população para reamostragem (amostra) relativamente grande, para que características da variabilidade populacional seja captada. A boa cobertura também depende da suposição de que as diferenças etimadas são normalmente distribuídas, porém, é desconhecido o quão grande é o tamanho amostral deveria ser antes de que a aproximação seja considerada, particularmente quando a distribuição é assimétrica.

Quando os tamanhos amostrais são pequenos, todas as indicações são de que o método de percentil por bootstrap é o melhor, então este é recomendado, até existir boa evidência de que algum outro método possa ser utilizado em seu lugar.

Nota-se que com o objetivo de comparar dois M-estimadores, de dois grupos independentes, precisa-se a cada replicação obter uma estimativa do parâmetro de interesse. Com isso, será utilizado algum algoritmo, como M.P.I. (médias ponderadas iteradas), M.P.V.I. (média de pseudovalores iterados) ou N.R. (Newton Raphson) .

## Comparação de média aparadas e medianas

Quando se compara médias aparadas e se tem pelo menos 20% dos dados desconsiderados para o seu cálculo, inferências baseadas no percentil pelo método de bootstrap é preferível quando comparado com o método de bootstrap-t (quando se utiliza a distribuição t de Student para determinar o valor crítico apropriado). A acurácia para o método de bootstrap-t é maior quando a quantidade de dados desconsiderados é pequena, mas há incertezas a respeito desse valor.

Para o caso no qual o objetivo é comparar as medianas, uma pequena mudança deve ser feita para quando se tem dados repetidos. Seja  $M_1^*$  e  $M_2^*$  medianas amostrais por bootstrap e  $p^* = P(M_1^* > M_2^*) + 0,5P(M_1^* = M_2^*)$ . De maneira semelhante ao que foi determinado anteriormente para  $p^*$ , entre B amostras de bootstrap se A é o número de vezes em que  $M_1^* > M_2^*$ , e C é o número de vezes em que  $M_1^* = M_2^*$ , uma estimativa para  $p^*$  é:  $p^* = \frac{A}{B} + 0,5\frac{C}{B}$ . Assim, o p-valor é definido como  $2\min(p^*, 1 - p^*)$ .

Em termos de controle da probabilidade do erro do tipo 1, as indicações até o momento são de que o método de inferência baseada em percentil por bootstrap tem um bom desempenho independente de existir dados repetidos.

Com a dúvida levantada a respeito da precisão do método de bootstrap-t, de acordo com Keselman et al. (2004), este tem uma performance razoável quando se desconsidera uma quantidade de 10% e 15% dos dados.

Por exemplo, considere a situação na qual se tem duas amostras definidas como segue:  $n_1 = 40$  observações de uma amostra de distribuição normal padrão e  $n_2 = 20$  observações de uma amostra de distribuição lognormal deslocada, tal que a média aparada tenha seja zero. Quando se testa a diferença entre os valores das médias, com nível de significância de 0,05, e 10% da informação amostral retirada, observa-se que o nível verdadeiro para o método bootstrap-t é 0,066 comparado com 0,050 para o método de percentil por bootstrap (ao usar 1000 réplicas). Ao se reduzir o tamanho amostral  $n_1 = 20$  e  $n_2 = 10$  as estimativas do nível de significância verdadeiros são: 0,082 e 0,074 para os métodos de bootstrap-t e o de percentil por bootstrap. Agora, para o último tamanho amostral fixo, e uma quantidade de informação retirada de 20% (isto é, nível de aparada de 20%), as estimativas dos níveis são 0,081 e 0,063, para o método de bootstrap-t e o percentil via bootstrap. Isto nos indica que o controle que se tem da probabilidade do erro do tipo 1 ao utilizar o método de percentil por bootstrap é maior quando comparado com o método de bootstrap-t. Este controle é maior ainda ao se considerar uma porcentagem de informação desconsiderada (nível de aparada).